

Luận văn Thạc sĩ — Tóm tắt tiến độ 2026

Giai đoạn: 01/01/2026 → 27/07/2026 · 517 commit · 54 pull request (#137 → #190)
(Bản chi tiết: [THESIS_PROGRESS_2026_VI.md](#))

Mỗi tháng được trình bày theo 5 mục: thay đổi kỹ thuật · dữ liệu · mô hình · các lần chạy & tham số · kết quả & metric.

Toàn cảnh

Tháng	Commit	Thay đổi kỹ thuật	Dữ liệu	Mô hình	Metric
01	3	Đổi nguồn tỷ giá	EXCHANGE_RATE	—	—
02	17	Bỏ tsfresh → CNN	VN-Index	CNN	—
03	78	TensorBoard, log run	+ HNX index	CNN	chỉ trong TensorBoard
04	93	ta_functions.py	+ đặc trưng TA	—	xếp hạng XGBoost
05	125	CSDL medallion 3 tầng	Toàn bộ HOSE	CNN	R ² dương (không ghi số)
06	98	BaseScraper + registry	+ CafeF, GICS, Simplize	LSTM	test R ² 0.007, AUC 0.505
07	103	Framework model/common	+ BCTC từ PDF, tin tức	LSTM ×27, PhoBERT	AUC 0.505 / 0.519 / 0.545

Tháng 01 — Tỷ giá

Thay đổi kỹ thuật. Viết lại luồng thu thập tỷ giá (154 dòng thêm / 82 xóa). Merge PR #137.
Dữ liệu. Chuyển EXCHANGE_RATE sang nguồn khác do nguồn cũ không đạt yêu cầu làm đầu vào mô hình.
Mô hình · Lần chạy · Metric. Không có.

Tháng 02 — Từ tsfresh sang CNN

Thay đổi kỹ thuật.

- Bỏ hướng trích xuất đặc trưng bề rộng bằng tsfresh (xóa 6.491 dòng), xây lại toàn bộ luồng quanh mô hình tích chập.
- Sửa lỗi kích thước tensor của dataloader — điểm nghẽn được đánh dấu bằng một commit CHECKPOINT riêng.

Dữ liệu. VN-Index (giá + lệnh). Bắt đầu tái xây dựng scraper vĩ mô (macroeconomics_gdp).

Mô hình. CNN 1 chiều chạy trực tiếp trên chuỗi thô, thay cho ma trận đặc trưng tsfresh.

Các lần chạy & tham số. Chưa có cơ chế cấu hình hay ghi tham số ra file; mọi tham số nằm trong notebook.

Kết quả & metric.

- Output thực tế đầu tiên: dự báo VN-Index đóng cửa 27/02/2026 = 1843.247.
- Chưa có metric out-of-sample được lưu lại.

Tháng 03 — Hạ tầng huấn luyện

Thay đổi kỹ thuật.

- Dựng **TensorBoard end-to-end**; mỗi lần chạy sinh một thư mục `version_N` riêng.
- `PostgreSQLDriver` hỗ trợ `join_clause`.
- Ghim phiên bản toàn bộ thư viện trong `requirements.txt` để loại trôi lệch môi trường.
- Thêm thông báo Windows khi huấn luyện xong.
- Khi phát hiện log thiếu metadata → hủy toàn bộ kết quả cũ và chạy lại từ đầu (xóa 168 file, rồi 152 file).

Dữ liệu. Hoàn thiện scraper + ingest + clean + transform cho VN-Index và HNX-Index (giá và lệnh).

Mô hình. Vẫn là CNN; 9 biến thể notebook `cnn_vn_index_1...9`.

Các lần chạy & tham số.

- Khoảng 80 lần chạy: `run_version_0...27`, sau đó khởi động lại thành `version_0...53`.
- Hai biến thể được thiết kế để so sánh trực tiếp: *validate sau khi scaling* (`cnn_vn_index_1`) vs *validate trước khi scaling* (`cnn_vn_index_2`).
- Notebook riêng xử lý hiện tượng overshoot khi huấn luyện.

Kết quả & metric.

- Metric chỉ tồn tại rời rạc trong TensorBoard của từng run, chưa được tổng hợp thành bảng so sánh.
- Chính hạn chế này dẫn tới việc lập `experiment_history.csv` ở tháng 6.

Tháng 04 — Thư viện đặc trưng

Thay đổi kỹ thuật.

- Viết ~60 hàm chỉ báo kỹ thuật (tương đương TA-Lib), mỗi hàm một commit: overlap, momentum, volume, cycle, price transform, volatility.
- Một đợt chuẩn hóa lại toàn bộ chữ ký hàm, sau đó xóa ~1.600 dòng mã cũ.
- Hai đợt tối ưu hiệu năng cho `ta_functions.py`.
- Thêm `SwitchHandler` + `switch_config.json` để bật/tắt từng tác vụ scrape độc lập.
- Scraper VN-Index chuyển sang quét phân trang với hàm chờ theo thay đổi nội dung (thay cho `sleep` cố định).

Dữ liệu. Bộ đặc trưng TA đầy đủ sinh từ OHLCV. Hai chỉ báo được khảo sát rồi loại bỏ có ghi nhận (`NO ADD: add_hilbert_transform`, `NO ADD: add_mesa_adaptive_moving_average`).

Mô hình. Không huấn luyện mô hình mới; tháng này tập trung vào đầu vào.

Các lần chạy & tham số. `feature_selection_vn_index.ipynb` — xếp hạng đặc trưng bằng `xgb.XGBRegressor`.

Kết quả & metric. Bảng xếp hạng độ quan trọng đặc trưng. Chưa có metric dự báo out-of-sample.

Tháng 05 — Kho dữ liệu medallion

Thay đổi kỹ thuật.

- Dựng schema **bronze / silver / gold**, sau đó xóa 3.427 dòng `CREATE TABLE` viết tay để chuyển sang suy luận schema tự động từ dataframe.
- Đa luồng hóa `PostgreSQLDriver` + thêm `ThreadManager`.
- Bổ sung cho driver: join nhiều cột, `IS / IS NOT NULL`, `IN / NOT IN`.
- Thêm `ipynb_to_txt.py` để review notebook qua diff.

Dữ liệu.

- Mở rộng scraper từ chỉ số sang **toàn bộ cổ phiếu HOSE**, rồi dữ liệu cấp doanh nghiệp.
- Scraper vĩ mô làm lại (USD/VND, lãi suất liên ngân hàng), chuẩn hóa theo TradingView.
- Bỏ các cột chỉ có một giá trị duy nhất.
- **Sửa lỗi khoảng train/val/test bị sai** → xóa hơn 316.000 dòng dữ liệu sinh ra không hợp lệ.

Mô hình. CNN (tiếp tục).

Các lần chạy & tham số.

- `train_test_creator` v2: cửa sổ trượt, chuẩn hóa `y` riêng, tham số `STRIDE`, lưu tensor + scaler cho cả 3 tập.
- `data_evaluator` v1 + `result_evaluator` — hoàn thiện nửa đánh giá của vòng lặp.

Kết quả & metric.

- R^2 dương đầu tiên trên tập test (commit `0081ebf`).
- ⚠ **Giá trị cụ thể không được ghi lại** — cơ chế log metric có hệ thống mãi tới 14/06 mới có. Kết quả này không tái lập được và **không nên trích dẫn trong luận văn**.

Tháng 06 — Ba nguồn dữ liệu, LSTM, và bước chuyển hướng

Thay đổi kỹ thuật.

- Tái cấu trúc scraper thành `BaseScraper(ABC)` + `registry/factory`; thêm nguồn mới chỉ cần một lớp con.
- Tổ chức lại dữ liệu thô theo `raw_data/<source>/`.
- **Tăng tốc ingest tầng gold ~4.5 lần** (68 → 15 phút): thay `pandas.to_csv` bằng `COPY FROM STDIN` + `pyarrow` — profiling cho thấy 88 % thời gian ở khâu insert, chỉ 12 % ở tính toán TA.
- Xử lý **vượt trần 1600 cột của PostgreSQL**: chỉ ghép các mã cùng ngành GICS (621 → 7–49 mã) thay vì toàn thị trường.
- Làm sạch giá trị cho kiểu `REAL`: `±inf` và `>3.4e38` → NaN, số dưới chuẩn `<1e-37` → 0.

Dữ liệu.

- Thêm 3 nguồn: **CafeF**, **GICS (MSCI 2023: 11/25/74/163)**, **Simplize** (OHLC điều chỉnh đầy đủ + khối lượng thực + dòng tiền ngoại từ 2009).
- Bật điều chỉnh cổ tức khi scrape TradingView.

- Chọn **Simplize làm nguồn chính** (đã kiểm chứng trên VN30); CafeF bổ sung khớp lệnh/thỏa thuận và sở hữu; TradingView chỉ dự phòng OHLC.
- Bảng `unified_<ticker>` cho **30 mã VN30**: VCB 4.213 dòng × 1.036 cột → sau làm sạch còn 1.015–1.025 cột.
- Biến mục tiêu: `pct_return` với horizon 5 ngày.

Mô hình. Chuyển từ CNN sang **LSTM** (PyTorch Lightning). Ba biến thể kiến trúc: `last_hidden` → `bidir_attn` (hai chiều + attention pooling).

Các lần chạy & tham số — 9 cấu hình ghi trong `experiment_history.csv` :

ID	Kiến trúc	Hidden	Lớp	Dropout	Loss	WD	LR	Batch	Epoch	Đặc trưng	Lookback
e01	last_hidden	128	2	0.2	MSE	1e-5	1e-3	64	100	200	20
e02	last_hidden	48	1	0.4	MSE	1e-3	1e-3	64	100	40	20
e03	bidir_attn	48	1	0.4	Huber	1e-3	1e-3	64	100	40	20
e04	bidir_attn	48	1	0.4	Huber	1e-3	1e-3	64	100	80	20
e05	bidir_attn	48	1	0.4	Huber	1e-3	1e-3	64	100	120	20
e06	last_hidden	48	1	0.4	BCE	1e-3	1e-3	64	100	40	20
e07/e08	bidir_attn (multitask)	48	1	0.4	Huber+BCE	1e-3	1e-3	64	100	80	40 / 20
e09	LSTM + ticker_emb	—	—	—	—	—	—	—	—	60	20

Chung cho mọi run: chia 70/15/15 theo thời gian · scaler `std` fit trên train · clip input ± 10 · horizon 5 ngày · TA điều chỉnh chu kỳ động (`dynta=yes`).
e09: bộ dữ liệu gộp 30 mã VN30 (52k/19k/19k cửa sổ) — **đã dựng xong nhưng chưa huấn luyện**.

Kết quả & metric.

ID	Cấu hình	Train R ²	Val R ²	Test R ²	Corr	Dir acc	Dir AUC
e01	Cơ sở	0.239	-0.184	-0.050	—	0.551	—
e02	+ regularization	0.040	-0.009	-0.009	0.008	0.407	—
e03	+ bidir/attn/Huber	0.057	-0.022	-0.012	0.058	0.464	—
e04	Chuẩn	0.065	0.003	0.007	0.141	0.483	0.505
e05	120 đặc trưng	0.066	-0.021	0.016	0.157	0.500	—
e06	Phân loại BCE	—	—	—	—	0.460	0.511

e01 → e02: overfitting được xử lý (khoảng cách train–val từ **0.42** → **0.05**). Nhưng R² test chỉ đi từ -0.050 lên **0.007** — tức vừa đúng bằng dự đoán giá trị trung bình. AUC 0.505 ≈ 0.5: **không phân biệt được ngày tăng và ngày giảm**. e05 có R² test cao nhất (0.016) nhưng val âm → val và test mâu thuẫn, là nhiễu.

Metric từ các thí nghiệm khảo sát tín hiệu:

Thí nghiệm	Nội dung	Kết quả
exp_1	GBM dò breakout +5 %/5 ngày (VCB)	AUC 0.77 (VN30 gộp $\approx$ 0.65)
exp_3	Backtest walk-forward VCB long/flat	Sharpe 0.67 vs mua-nắm-giữ 0.66
exp_3	Long/short cross-sectional VN30	Sharpe -0.53, drawdown -88 %
exp_3	So sánh 6 biến mục tiêu	Tốt nhất rel5 , rank IC 0.052 — không cái nào thắng thị trường sau phí
—	Cross-sectional VN30 (Ridge, walk-forward 10 năm)	rank IC +0.03; sau phí 40 bps: L/S +6.6 %/năm, long-only +3.9 %/năm

Bước ngoặt: AUC 0.77 nghe rất cao nhưng backtest cho thấy nó chỉ là **bộ dò chế độ biến động** — Sharpe 0.67 ngang hệt mua-và-nắm-giữ 0.66, không tạo alpha. Kết luận: ràng buộc là *dữ liệu*, không phải mô hình.

Tháng 07 — Dữ liệu trực giao

Thay đổi kỹ thuật.

- `src/model/common/` — framework huấn luyện tái sử dụng: tham chiếu dataset bằng content-hash, thư mục run bất biến (ghi kèm config + git SHA + môi trường), vòng lặp GPU, early stopping, TensorBoard, checkpoint best/last, bảng xếp hạng chỉ-ghi-thêm `runs/index.csv`.
- Cấu hình chuyển sang file **YAML** thay vì tham số trong notebook → mỗi run tái lập được.
- Pipeline OCR đọc PDF: `cafef_pdf_scraper` → `cafef_pdf_parser` → `cafef_financials`, với kiến trúc **ParseLayer** thử lần lượt `onnx@200` → `onnx@300` → `onnx@400` → `tesseract@200` → `+relax`.
- Sửa `ThreadManager`: công thức cũ cho ra số luồng thập phân (2.4 trên máy 20 nhân) nên pool luôn chạy ~2 luồng → thêm `max_workers` tương minh (mặc định 16).
- Sửa lỗi `LIKE` trong SQL: ký tự `_` khớp mọi ký tự nên `lb2__%` khớp cả `lb20`.

Dữ liệu.

- BCTC quý bóc tách từ PDF scan tiếng Việt** — 4 hệ thống tài khoản (ngân hàng / doanh nghiệp / chứng khoán / bảo hiểm); ~90 % báo cáo VCB là ảnh scan không có tầng text.
- Tách khóa `EXCHANGE:TICKER` thành 2 cột riêng trên toàn bộ bronze; chuẩn hóa tên cột xuyên suốt.
- `silver.stocks_basic`: 2.388.368 dòng × 38 cột, 99.7 % số dòng có phân ngành GICS.
- `silver.stocks_basic_financials_bank`: ghép giá ngày × BCTC quý qua `merge_asof` theo `publish_date` → không look-ahead (4.235 dòng × 216 cột).
- `silver.stocks_basic_financials_bank_fa`: +26 chỉ số cơ bản (242 cột).
- Kho tin tức 777 mã, ~405 nghìn dòng; kho PDF ~97 GB (VN100).

Mô hình.

- LSTM (giữ nguyên kiến trúc từ tháng 6) nhưng **task-aware**: hồi quy (MSE) và phân loại (BCEWithLogitsLoss) dùng chung `model.py`.
- PhoBERT** 3 lớp cho sentiment tiếng Việt + bộ phân loại text → nhãn phản ứng giá.

Các lần chạy & tham số — 27 run ghi trong `runs/index.csv` :

Nhóm	Biến mục tiêu	Task	Loss	Lookback	Số đặc trưng	Số run
(a)	<code>return_5day</code>	Hồi quy	MSE	1,2,3,5,10,15,20,25,30	139–156	9
(b)	<code>direction_5day</code>	Phân loại	BCE	1,2,3,5,10,15,20,25,30	145–167	9
(c)	<code>probability_gain_5pct_5day</code>	Phân loại	BCE	1,2,3,5,10,15,20,25,30	130–160	9

Chung: VCB · horizon 5 ngày · chia 70/15/15 · scaler `std` · early stopping trên val.
⚠ `best_epoch` của phần lớn run là 1–5 (chỉ lb30 đạt 25) — mô hình ngừng cải thiện gần như ngay lập tức, một dấu hiệu trực tiếp cho thấy không có gì để học.

Kết quả & metric.

(a) Hồi quy `return_5day` — chuẩn so sánh: RMSE của dự báo-bằng-0 = **0.035748**

Lookback	1	2	3	5	10	15	20	25	30
Test RMSE	0.0368	0.0430	0.0398	0.0374	0.0448	0.0402	0.0425	0.0447	0.0378
Test AUC	0.551	0.560	0.520	0.506	0.474	0.453	0.465	0.496	0.518
Test IC	0.114	0.120	−0.032	0.022	−0.063	−0.166	−0.097	−0.043	0.027

→ **0/9** run vượt chuẩn so sánh. Tốt nhất (lb1) vẫn tệ hơn **2.9 %** so với dự báo hằng số 0. AUC trung bình **0.505**.

(b) Phân loại `direction_5day` — tỷ lệ lớp đa số 0.4355

Lookback	1	2	3	5	10	15	20	25	30
Test AUC	0.523	0.523	0.528	0.549	0.500	0.526	0.473	0.540	0.512

→ AUC trung bình **0.519** (0.473–0.549). Chỉ 1/9 run vượt lớp đa số, lookback lân cận không xác nhận → nhiễu.

(c) Phân loại `probability_gain_5pct_5day` — tỷ lệ nền 0.0708

Lookback	1	2	3	5	10	15	20	25	30
Test ROC-AUC	0.641	0.411	0.539	0.518	0.518	0.655	0.501	0.643	0.477
Test PR-AUC	0.129	0.089	0.103	0.118	0.097	0.120	0.079	0.110	0.108

→ ROC-AUC trung bình **0.545**, PR-AUC trung bình **0.106** (nền 0.071). Nhìn qua có vẻ khá hơn (b), **nhưng val và test nghịch nhau**: lb15 có AUC val tệ nhất (0.332) lại cho AUC test tốt nhất (0.655) → không tái lập được.

Cross-sectional:

Nội dung	Kết quả
Bộ phân loại tốt nhất ngoài mẫu (XGB, mục tiêu trung hòa ngành)	AUC 0.52 toàn bộ / 0.53 tercile
Sharpe gộp long/short	1.3 – 1.6
Vòng quay	65–78 %/vẽ/tuần → triệt tiêu lợi nhuận
Ròng @20 bps sau kiểm soát vòng quay	+0.46 — nhưng +1.46 (2017-20) vs –0.51 (2022-26)
Riêng VCB	AUC tương đối ngành 0.491 , tuyệt đối 0.518 , Sharpe ròng –0.12

Sentiment:

Bài toán	Kết quả
Nhãn suy ra từ chính văn bản	QWK 0.61 ✓
<code>close[N+5]</code>	0/7 lần vượt bước ngẫu nhiên
Hướng giá	AUC $\approx$ 0.49
Xác suất tăng ≥ 5 % (nền 11.3 %)	AUC $\approx$ 0.50
Nhãn theo phản ứng giá 5 mức	QWK $\approx$ 0.00
Thêm sentiment lên trên giá/TA	AUC 0.543 → 0.534 ; QWK 0.175 → 0.045 ✗ làm xấu đi

Bóc tách BCTC:

Mã	Khoảng	Số ô	Đọc được từ PDF
VCB	Q3-2008 → Q1-2026 (71 quý)	213	213/213 (100 %)
ACB	Q1-2010 → Q1-2026 (65 quý)	195	195/195 (100 %)

Kiểm chứng chỉ số cơ bản VCB kỳ mới nhất: **P/E 14.13 · P/B 2.56 · ROE 22.2 % · NIM 2.69 %**.

Tổng hợp: mô hình hiện đang có gì

Bài toán	Metric tốt nhất	Chuẩn so sánh	Kết luận
Lợi suất 5 ngày (VCB)	R^2 0.007 , RMSE 0.0368	R^2 0, RMSE 0.0357	✗ Không vượt
Hướng giá 5 ngày (VCB)	AUC 0.549	0.50	✗ Nhiều
Xác suất tăng ≥ 5 % (VCB)	AUC 0.655	0.50	✗ Không tái lập
Sentiment → giá	AUC 0.49–0.50	0.50	✗ Bằng ngẫu nhiên
Breakout GBM (VCB)	AUC 0.77	0.50	⚠ Cao nhưng Sharpe 0.67 $\approx$ mua-nắm-giữ
Cross-sectional VN30	rank IC +0.03 , L/S +6.6 %/năm	thị trường	✓ Dương ròng duy nhất

Diễn giải. Với dữ liệu giá + chỉ báo kỹ thuật + sentiment, mọi bài toán ở cấp **một cổ phiếu đơn lẻ** đều cho AUC trong khoảng 0.47–0.55 — gần như không phân biệt được gì so với tung đồng xu. Trường hợp duy nhất có AUC cao (0.77) hóa ra là dò *chế độ biến động* chứ không phải dò *hướng giá*, và backtest chứng minh điều đó. Kết quả dương duy nhất nằm ở **cấp danh mục**, và ngay cả nó cũng suy giảm rõ sau 2021.

Kết luận này được rút ra từ nhiều góc độ độc lập — nhiều kiến trúc (LSTM/GRU/CNN/Transformer/GBM), nhiều biến mục tiêu (lợi suất, hướng, ngưỡng, tương đối), nhiều lookback (1→30), nhiều cách chia dữ liệu, có tính chi phí giao dịch — chứ không phải từ một thí nghiệm đơn lẻ. **Đó là giá trị học thuật của luận văn: một kết quả phủ định được chứng minh chặt chẽ.**

Hạ tầng dữ liệu cơ bản xây trong tháng 7 (BCTC, ngày công bố, số cổ phiếu, tin tức) là để mở đường cho hướng chưa được kiểm chứng: **liệu dữ liệu cơ bản có bổ sung thông tin mà giá không có.**

Việc còn dở dang

1. Mô hình gộp 30 mã VN30 chưa huấn luyện — dữ liệu đã dựng xong (52k/19k/19k cửa sổ, dòng e09), chỉ còn chạy. Đây là thí nghiệm rẻ nhất còn lại.
2. Chưa mô hình nào dùng dữ liệu cơ bản — bảng 26 chỉ số FA vừa xong tháng 7, chưa vào thí nghiệm nào.
3. Kiểm thử hồi quy 2 sửa lỗi OCR cuối chưa hoàn tất (~50–60 phút) — cần chạy trước khi dùng parser ngoài phạm vi ACB.
4. Mới bóc tách 2 mã (VCB, ACB) và 1 trong 4 template kế toán; bảng FA hiện chỉ có VCB.
5. Thí nghiệm sentiment mới chạy trên 3 mã.